PROJETO E OBJETIVO

Classificar registros. Compreender os limites.

Segurança pública inteligente em São Paulo

Uma MLP para distinguir **roubo** e **furto simples** em ocorrências já registradas ou hipotéticas na capital.

20.000
BOs na amostra

3
arquiteturas testadas

62,77%
acurácia no teste

Matheus Moura da Silva | RM 566782 | Turma 2CCPR

PROBLEMA, FONTE E SELEÇÃO

Dados reais, recorte explícito.

Objetivo: classificar a natureza do registro; não estimar a chance de acontecer um crime.

- **Fonte:** espelho histórico nublia/data-science-playground, atribuído à SSP-SP e distribuído via data.world. Registros de 2016; acesso em 10/11/2026.
- **Capital:** departamento da circunscrição do fato = DECAP e CIDADE = S.PAULO. A delegacia de registro não define o local do crime.
- **Seleção:** roubo ou furto simples consumado; exclusão de BOs com rubricas ou dados conflitantes; deduplicação por ano + delegacia + número.
- **Volume:** 770.371 linhas de origem → 404.108 BOs elegíveis → amostra estratificada de 20.000 (10.016 furtos / 9.984 roubos).
- **Entradas:** distrito do fato e mês de registro, escolhidos pela disponibilidade e pelo contexto territorial/temporal. Sem dados pessoais ou campos jurídicos.

Espelho e documentação | Portal oficial SSP-SP | Hash SHA-256 e etapas no notebook.

PREPARAÇÃO DOS DADOS

Separar antes de aprender.

Entrada	Tratamento	Justificativa
Distrito do fato	One-hot: 93 categorias	Contexto local sem ordem artificial
Mês de registro	One-hot: 12 categorias	A data/hora do fato não existe no CSV limpo
Rubrica	Somente alvo: 0 furto / 1 roubo	Excluída das entradas para evitar vazamento

- Textos normalizados; ausência de distrito receberia “NAO INFORMADO”. A amostra final não tem ausências nas entradas. Sem variáveis contínuas: não se aplica escalonamento.
- Encoder ajustado apenas no treino. BOs únicos e conjuntos disjuntos: **14.000 treino / 3.000 validação / 3.000 teste**; estratificação e semente 42.

ARQUITETURA E FUNCIONAMENTO

A MLP selecionada tem 1.713 parâmetros.

Rede A: 105 entradas → 16 neurônios ReLU → 1 saída sigmoid.

105 entradas

93 distritos + 12 meses
One-hot com valores 0/1

→

16 neurônios

Camada densa
h = ReLU(XW + b)

→

1 saída

p(roubo) = sigmoid(hW + b)
p(furto) = 1 - p(roubo)

- Camadas densas combinam todas as entradas por pesos e vieses. ReLU permite relações não lineares; sigmoid produz a saída binária.
- Limiar fixo: p(roubo) ≥ 0,5 → roubo; caso contrário → furto. Os percentuais não tiveram calibração validada.
- Implementação real com MLPClassifier (scikit-learn). O enunciado pede MLP tabular; não exige uma CNN.

CONFIGURAÇÃO DO TREINAMENTO

Treino controlado pela validação.

Componente	Configuração adotada
Perda / saída	Entropia cruzada binária + L2 nos pesos; sigmoid
Otimizador	Adam; beta1 = 0,9; beta2 = 0,999; epsilon = 1e-8
Taxa de aprendizado	A e B: 0,001; C: 0,0005
Épocas / lotes	Máximo 100 épocas; batch size 128; embaralhamento; semente 42
Parada e seleção	F1 macro na validação; paciência 12; melhoria mínima 0,0001
Pesos entregues	Rede A, época 6; parada após 18 épocas; limiar 0,5

partial_fit preserva o estado de Adam. Os pesos escolhidos são restaurados; o teste não define arquitetura ou época.

EXPERIMENTAÇÃO

Mais camadas não trouxeram ganho.

Modelo	Ocultas / parâmetros	L2 alpha / taxa	Hipótese testada
A · compacta	16 / 1.713	0,0001 / 0,001	Referência de baixa capacidade
B · intermediária	64 → 32 / 8.897	0,0001 / 0,001	Maior capacidade e profundidade
C · regularizada	128 → 64 → 32 / 23.937	0,01 / 0,0005	Profundidade com L2 mais forte e passos menores

- Mesmo recorte, divisão e encoder para os três experimentos. Melhor época: A = 6; B = 3; C = 3.
- B e C ficaram abaixo de A no F1 macro de validação. A diferença é pequena; uma semente não comprova superioridade estatística.
- C muda vários fatores simultaneamente: não é possível atribuir seu resultado apenas à regularização.

AVALIAÇÃO E ESCOLHA

A vence na validação; teste fica reservado.

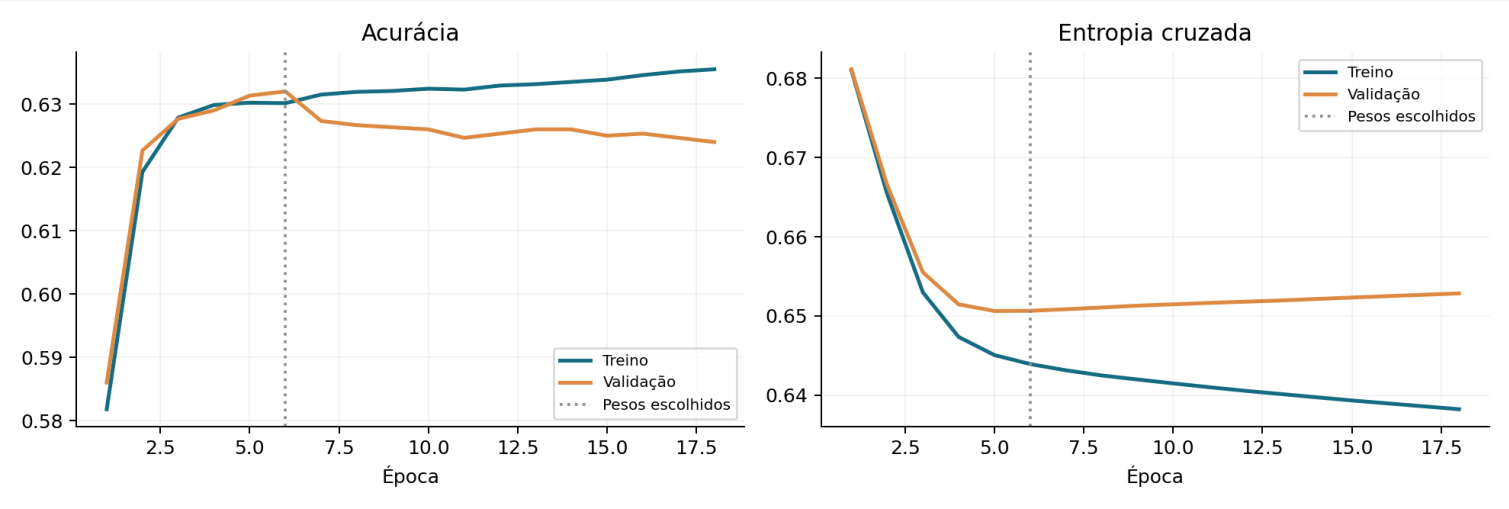
Precision, recall e F1 usam roubo como classe positiva. F1 macro considera ambas as classes.

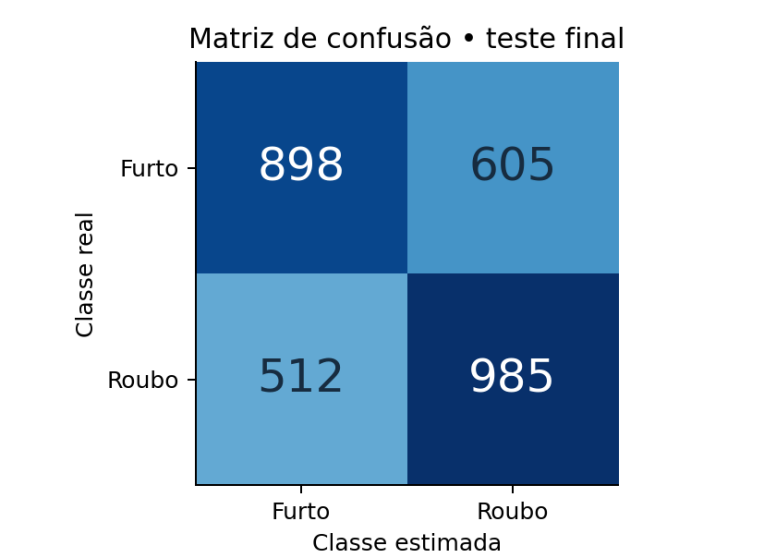
Conjunto / modelo	Acurácia	Precision	Recall	F1 roubo	F1 macro
Validação · A	63,20%	62,28%	66,69%	64,41%	63,16%
Validação · B	62,87%	61,94%	66,49%	64,13%	62,82%
Validação · C	62,40%	61,98%	63,89%	62,92%	62,39%
Teste final · A	62,77%	61,95%	65,80%	63,82%	62,74%

- Seleção por **F1 macro de validação = 63,16%**. Arquitetura, pesos e limiar congelados antes do teste.
- Baseline majoritária no teste: 50,10% de acurácia e 33,38% de F1 macro. Ganho de acurácia da rede: **12,67 pontos percentuais**.

CURVAS, MATRIZ E DIAGNÓSTICO

Overfitting leve após a melhor época.





- Época 6: acurácia treino/validação = 63,01% / 63,20%; perda = 0,6439 / 0,6507. As curvas mostram entropia cruzada sem o termo L2.
- A perda de treino segue caindo e a de validação sobe levemente. Early stopping restaura a época 6. A baixa informação das entradas também limita o desempenho.
- Teste: 898 furtos e 985 roubos corretos; 605 furtos confundidos com roubo e 512 roubos com furto. São **1.117 erros em 3.000 casos**.

APLICAÇÃO WEB

Acesso público e formulário testado.

Página inicial do site publicado. Testes de interação realizados no navegador, sem autenticação.



TESTES REALIZADOS

Distrito vazio: classificação impedida.
Sé / Janeiro
Furto 68,6% | Roubo 31,4%
Capão Redondo / Dezembro
Roubo 66,0% | Furto 34,0%

Categorias one-hot e pesos em JSON; ReLU e sigmoid calculadas no navegador. Paridade Python/JavaScript em 200 casos: erro máximo de $1{,}11 \times 10^{-16}$.

Abrir aplicação pública - não exige login · Percentuais classificam um registro; não medem risco de acontecer um crime.

CONCLUSÕES, LIMITES E IA

Um experimento reproduzível, com alcance limitado.

- **Resultado:** três MLPs treinadas, comparação em validação e teste final reservado. A rede compacta foi a melhor neste recorte; acurácia de 62,77% no teste.
- **Limitações:** dados secundários de 2016, duas entradas, subnotificação, chave de deduplicação operacional e uma única semente. Sem validação temporal ou calibração.
- **Interpretação:** o modelo aprende padrões contextuais, não o critério jurídico de violência/ameaça. Não usar para decisões policiais ou estimar risco de vitimização.
- **IA generativa:** ChatGPT apoiou programação, depuração, documentação e relatório. Métricas e curvas foram calculadas em execução real; a equipe deve revisar e compreender o código.
- **Antes da entrega:** enviar o projeto ao GitHub e entregar os materiais pelo portal da faculdade. A aplicação pública já foi testada no navegador.

Próximos experimentos: fonte oficial recente, dicionário auditado, mais variáveis do fato, múltiplas sementes e validação temporal.